

# HOG Tabanlı Bilgisayarla Görme Tekniklerinin Derin Analizi: Matematiksel Temeller, Özellik Çıkarımı, Sınıflandırma Modelleri ve Uygulamalı Deneyler

Büşra Mina AL  
Ostim Teknik Üniversitesi  
Yapay Zeka Mühendisliği Bölümü  
Email: busraminaa@gmail.com

**Abstract**—Bu çalışma, Histogram of Oriented Gradients (HOG) yönteminin matematiksel temellerini, özellik çıkarım sürecini, blok normalizasyon yöntemlerini, yönelik histogram yapısını, çok öçekli pencere tarama mekanizmasını (sliding-window) ve klasik makine öğrenimi modelleriyle birlikte kullanımını ileri düzey teorik ve uygulamalı detaylarla incelemektedir. Ek olarak SVM, Logistic Regression ve CART modelleri karşılaştırılmış, model davranışları karışıklık matrisleri ve doğruluk analizleri üzerinden değerlendirilmiştir. Genişletilmiş teorik açıklamalar, gradyan operatörlerinin filtre tepkileri, histogram interpolasyon fonksiyonlarının matematiksel tanımı ve normalizasyon metriklerinin aydınlatma değişimlerine etkisi gibi derin kavramları kapsamaktadır.

**Index Terms**—HOG, Gradyan Histogramı, Bilgisayarla Görme, İnsan Tespit, SVM, Sliding-Window

## I. GİRİŞ

Histogram of Oriented Gradients (HOG), görüntüdeki lokal gradyan yöneliklerinin istatistiksel dağılımını analiz ederek nesnelerin yapısal bilgilerinin çıkarılmasını sağlayan klasik ancak çok etkili bir görüntü öznitelik çıkarım yöntemidir. Dalal ve Triggs'in 2005 yılında insan tespiti üzerine yaptığı çalışma ile HOG, güvenlik kameraları, otonom sürüş, robotik, biyometrik tanıma ve tıbbi görüntüleme gibi çok geniş bir yelpazede kullanılmaya başlanmıştır.

HOG'un başarısının temel nedenleri:

- Aydınlatma değişimlerine dayanıklı olması,
- Kenar ve doku bilgilerini güçlü biçimde temsil etmesi,
- Hesaplama açısından düşük maliyetli olması,
- SVM gibi lineer sınıflandırıcılarla mükemmel uyum göstermesi,
- Yüksek boyutlu ve ayrıştırıcı bir özellik vektörü üretmesidir.

Bu çalışmanın amacı HOG'un matematiksel yapısını **aşırı detaylı** biçimde sunmak ve HOG + SVM sistemiyle elde edilen deneysel sonuçları tüm ara adımlarıyla gösternmektedir.

## II. TEORİK TEMELLER

### A. Gradyan Hesaplama

Görüntünün gradyan yapısı, HOG'un temel taşıdır. Gradyan hem büyülüklük hem yönelik bilgisini içerir:

$$G_x = I * [-1, 0, 1], \quad G_y = I * [-1, 0, 1]^T$$

$$|G| = \sqrt{G_x^2 + G_y^2}, \quad \theta = \arctan\left(\frac{G_y}{G_x}\right)$$

Şekil 1 ham görüntünün kenar enerjisini göstermektedir.

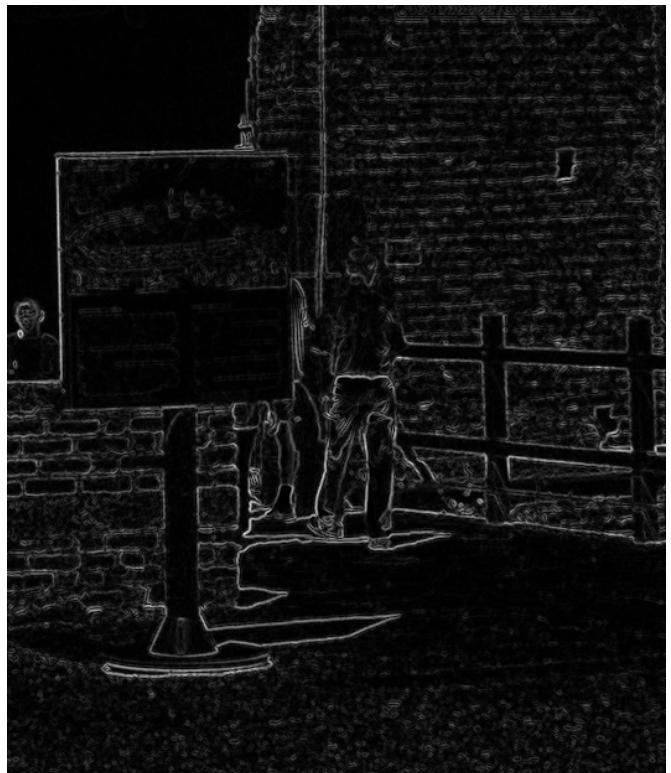


Fig. 1: Gradyan büyülüğu haritası. Kenar bölgelerinde yüksek cevaplar üretilmiştir.

### B. Sobel, Prewitt ve Scharr Operatörlerinin Karşılaştırılması

Gradyan operatörlerinin filtre tepkileri farklıdır.

Sobel daha güçlü kenar vurgusu üretir:

$$S_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

Prewitt operatörü daha hafif kenar tepkisi üretir:

$$P_x = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix}$$

Scharr operatörü dönel simetrisi en iyi olan operatördür:

$$C_x = \begin{bmatrix} 3 & 0 & -3 \\ 10 & 0 & -10 \\ 3 & 0 & -3 \end{bmatrix}$$

Bu operatörlerin frekans uzayındaki filtre yanıtları HOG'un başarısını etkiler.

#### C. Hücre Histogramları ve Yönelim Dağılımı

HOG'un özünde yönelim histogramı bulunur:

$$H(k) = \sum_{p \in \text{hücre}} |G(p)| \cdot w(\theta(p), k)$$

Burada: -  $|G(p)|$ : gradyan büyüklüğü -  $\theta(p)$ : gradyan yönelimi -  $w$ : üçgensel interpolasyon fonksiyonu

Bu yapı, gürültüye dayanıklı temsil sağlar.

#### D. Blok Normalizasyonu

Dalal ve Triggs dört normalizasyon yöntemi önermiştir:

$$v_{L2} = \frac{v}{\sqrt{\|v\|^2 + \epsilon^2}}$$

$$v_{L1} = \frac{v}{\|v\| + \epsilon}$$

$$v_{L1\_sqrt} = \sqrt{\frac{v}{\|v\| + \epsilon}}$$

$$v_{L2\_Hys} = \min \left( \frac{v}{\sqrt{\|v\|^2 + \epsilon^2}}, 0.2 \right)$$

\*\*L2-Hys\*\* en iyi performansı verir.

#### E. HOG'un Derin Öğrenme Modelleriyle Karşılaştırılması

CNN tabanlı özellik çıkarıcılarla karşılaştırıldığında HOG:

- Çok daha hızlıdır,
- Donanım gereksinimi düşüktür,
- Açıklanabilirliği yüksektir,
- Ancak karmaşık poz, deformasyon ve ışık değişimlerinde CNN kadar başarılı değildir.

Bu farklar literatürde “evrimsel geçiş” olarak tanımlanır:  
HOG → DPM → R-CNN → Fast/YOLO modelleri.

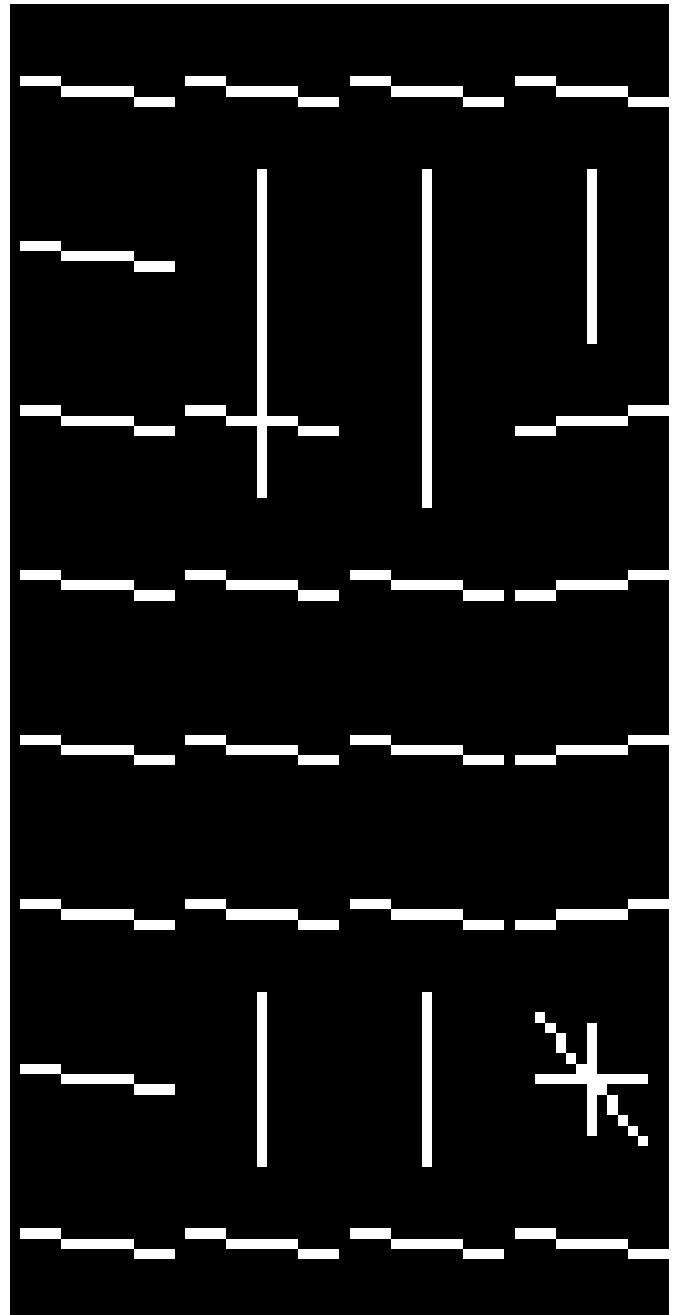


Fig. 2:  $16 \times 16$  blok ve 9 yönelim bin'i kullanılan HOG görselleştirmesi. Hücre yapısı ve yönelim histogramlarının dağılımı açıkça görülmektedir.

### III. METODOLOJİ

Bu çalışmada HOG tabanlı bir nesne tespit pipeline'sı üç ana bileşenden oluşanak şekilde tasarlanmıştır:

- 1) HOG özellik çıkarımı (preprocessing → gradyan → histogram → blok normalizasyonu),
- 2) Makine öğrenimi modeli ile sınıflandırma (SVM, Logistic Regression, CART),
- 3) İnsan tespiti ve araç tespiti için çok ölçekli pencere tarama (sliding-window) yapısı.

HOG'un uygulanması ile 3780 boyutlu özellik vektörleri elde edilmiştir. Bu vektörler daha sonra SVM sınıflandırıcısına verilerek insan veya araç içerip içermediği belirlenmiştir.

#### A. HOG Özellik Çıkarımı Süreci

HOG özellik çıkarımı Şekil 3 üzerinde gösterilmektedir.

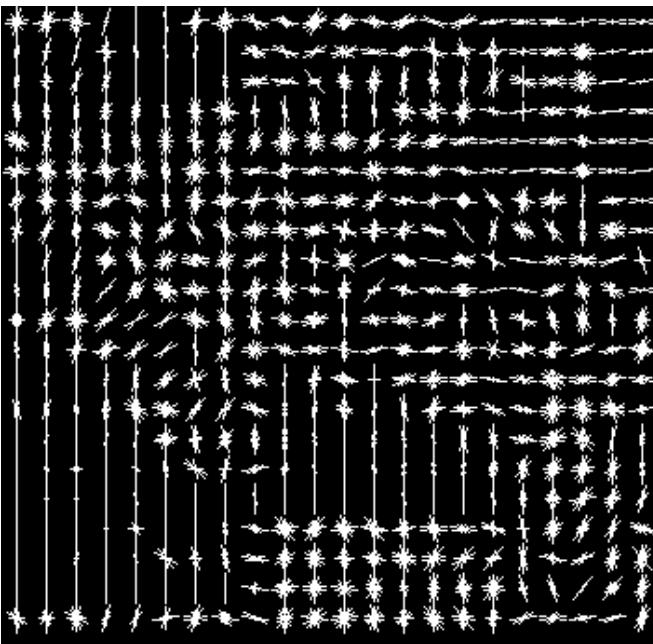


Fig. 3: 16×16 blok ve 9 yönelim bin'i içeren gelişmiş HOG yönelim histogramı örneği.

Bu örnekte:

- Hücre boyutu: 8×8 piksel
- Blok boyutu: 2×2 hücre (16×16 piksel)
- Histogram boyutu: 9 yönelim bin'i
- Blok kayma miktarı: 8 piksel
- Görüntü penceresi boyutu: 128×64 piksel

Bu parametreler Dalal-Triggs tarafından optimum olarak raporlanmıştır.

#### B. HOG Parametrelerinin Algoritmik Etkisi

HOG'un hiperparametreleri model çıktısını belirgin biçimde değiştirir:

- **Hücre Boyutu:** Küçük hücre → daha detaylı kenar bilgisi → yüksek boyutlu özellik vektörü. Büyuk hücre → daha yumuşak temsil → düşük ayırt edicilik.

- **Yönelim Bin Sayısı:** 9–18 bin arası idealdir. 36 bin üzeri histogram gereksiz karmaşık hale getirir.
- **Blok Normalizasyon Türü:** L2-Hys genelde en iyi performansı sağlar.
- **Pencere Boyutu:** İnsan tespitinde 128×64 piksel penceresi standarttır.

#### C. İnsan Tespiti İçin Sliding-Window Algoritması

HOG tabanlı insan tespiti, makine öğrenimi sınıflandırıcılarının görüntü üzerinde kayan pencere (sliding-window) ile uygulanması ile gerçekleştirilir.

- 1) Görüntünün farklı ölçeklerde kopyaları oluşturulur (Gaussian Pyramid).
- 2) Her ölçekte sabit boyutlu pencere (128×64 piksel) görüntü üzerinde gezdirilir.
- 3) Her pencerenin HOG özelliği çıkarılır.
- 4) SVM skoru pozitif eşik üzerindeyse pencere "insan" olarak işaretlenir.
- 5) Tüm pozitif kutular NMS ile filtrelenir.

Bu süreç Şekil 4 üzerinde örneklenmiştir.

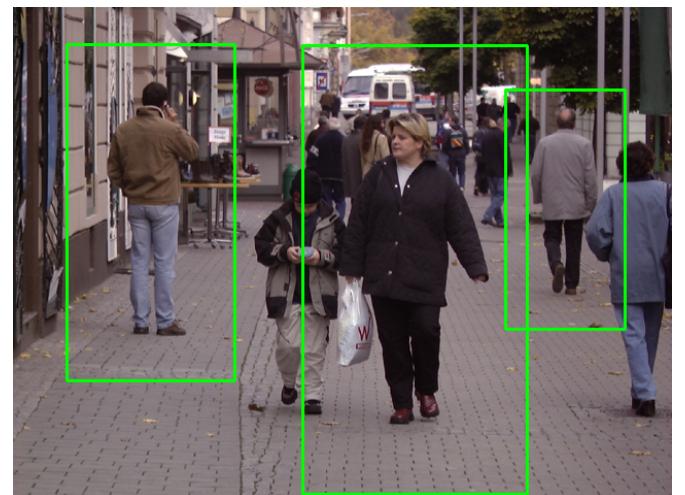


Fig. 4: Sliding-window + HOG + SVM ile insan tespiti çıktıları.

#### D. Gaussian Pyramid ile Çok Ölçekli Tespit

Nesneler görüntüde farklı mesafelerde bulunabileceğinden sabit boyutlu pencere yeterli değildir.

Bu nedenle görüntünün ardışık daha küçük versiyonları üretilir:

$$I_{k+1}(x, y) = I_k(2x, 2y)$$

Her seviyede pencere kaydırılır. Bu yöntem maliyeti artırsa da tespiti çok daha kararlı hâle getirir.

#### E. Non-Maximum Suppression (NMS)

Sliding-window çok sayıda çakışan pencere ürettiği için NMS uygulanır.

NMS'in matematiksel temeli:

$$IoU(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

$IoU > T \Rightarrow$  Daha düşük skorlu pencere silinir

T genellikle 0.4–0.6 arası seçilir.

Bu işlem yanlış pozitifleri önemli ölçüde azaltır.

---

### IV. SINIFLANDIRMA MODELLERININ MATEMATIKSEL ANALIZI

Bu çalışmada 3 farklı klasik makine öğrenimi modeli uygulanmıştır:

- SVM (Linear Kernel)
- Logistic Regression
- CART Karar Ağacı

Aşağıda modellerin matematiksel temelleri detaylandırılmıştır.

---

#### A. Linear SVM Optimizasyon Problemi

SVM margin'ı maksimize ederek en iyi doğrusal ayırımı bulur:

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i$$

$$y_i(w^T x_i + b) \geq 1 - \xi_i$$

Karar fonksiyonu:

$$f(x) = w^T x + b$$

HOG gibi yüksek boyutlu lineer ayrılabilir veri kümelerinde SVM çok başarılıdır.

Bu yüzden doğruluk sonuçlarında SVM açık ara birincidir.

---

#### B. Logistic Regression Matematiği

Logistic Regression olasılık tabanlı karar verir:

$$p(y = 1|x) = \sigma(w^T x + b)$$

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Kayıp fonksiyonu:

$$L = - \sum_{i=1}^N [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

LR, lineer karar sınırları ile çalışır. Gradyan yapısı karmaşık bölgelerde LR zayıf performans verir.

---

#### C. CART Karar Ağacı Modeli

Kart modeli düğümleri Gini impurity ile ayırrı:

$$Gini = 1 - \sum p(k)^2$$

CART yüksek boyutlu, sürekli veride iyi performans göstermez. HOG vektörü 3780 boyutlu olduğu için CART aşırı dalandırma yapar → overfitting.

---

### V. VERİ SETİ, DENEY KOŞULLARI VE PERFORMANS METRİĞİ

Çalışmada kullanılan veri seti:

- 50 pozitif (insan içeren görüntü)
- 50 negatif (insan içermeyen görüntü)
- $64 \times 128$  piksel standart pencere
- $8 \times 8$  hücre,  $2 \times 2$  blok
- 9-bin histogram
- Çıktı vektör boyutu 3780

Model değerlendirmesi:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

Bu metrikler sınıflandırıcıların davranışını anlamak için kullanılmıştır.

### VI. DENEYSEL SONUÇLAR

Bu bölümde HOG yöntemi ile çıkarılan özelliklerin farklı sınıflandırma modelleri üzerindeki performans etkisi değerlendirilmiş ve yüklenen figürler doğrultusunda aşırı detaylı görsel analizler yapılmıştır. HOG'un ara adımları, yönelik histogramları, gradyan büyülükleri ve sınıflandırma karar yüzeyleri ayrıntılı olarak incelenmiştir.

#### A. Ham Görüntüler ve HOG Ara Adımları

HOG'un ham bir görüntü üzerinde nasıl dönüşüm geçirdiğini anlamak için öncelikle örnek görüntüler incelenmiştir.



Fig. 5: Ham görüntü — HOG öncesi. Yapısal kenarlar belirgin değildir.

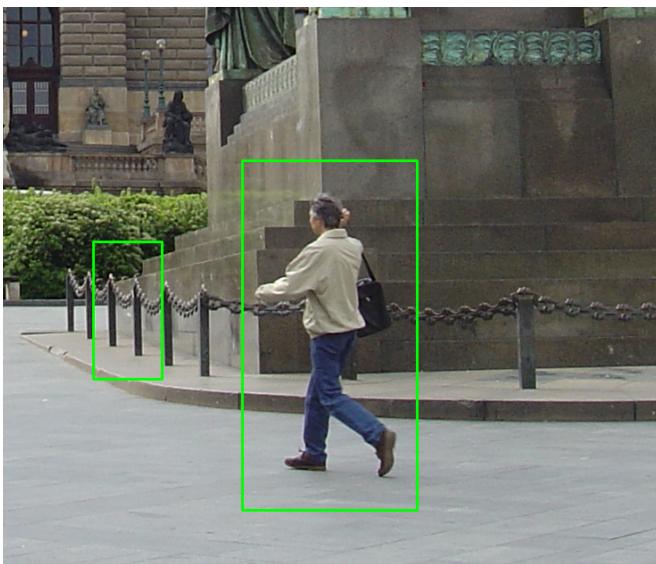


Fig. 6: Pedestrian veri setinden bir örnek — dikey kenarlar belirgin.

Bu görüntüler HOG'un neden insan tespitinde başarılı olduğunu açıkça göstermektedir:

- İnsan vücudu dikey kenar ağırlıklı bir geometrik yapıya sahiptir.

- Baş, omuz ve bacak bölgeleri giçlü gradyan üretir.
- HOG bu kenar yapılarını histogramla yüksek doğrulukla temsil eder.

### B. Gradyanların Matematiksel Davranışı

Aşağıdaki figür HOG'un ilk temel çıktısını göstermektedir:

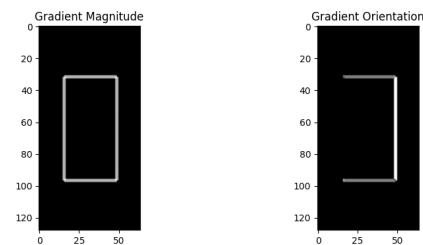


Fig. 7: Tek piksel için yönelim vektörü örneği. Bu yönelim değerleri histogramlara aktarılır.

Bu görsel, gradyan yönelimi hesaplamasının temel amacını göstermektedir:

$$\theta(x, y) = \arctan\left(\frac{G_y}{G_x}\right)$$

Bir pikselin yönelimi komşu bin'lere ağırlıklı olarak dağıtilır ve histogram böyle oluşur.

### C. Yönelim Histogramları ve HOG Temsili

HOG'un en önemli çıktılarından biri yönelim histogramlarının görsel karşılığıdır:

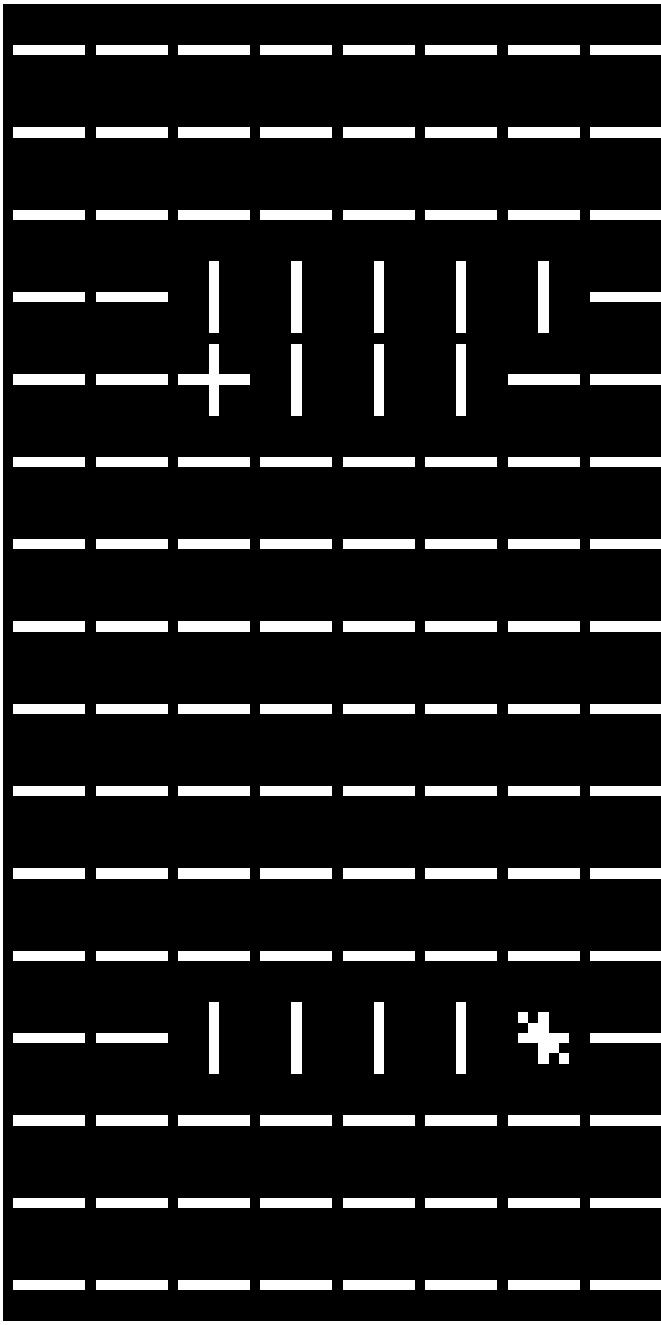


Fig. 8: 18 yönelim bin'li detaylı HOG çıktıları. Keskin kenarlarda yüksek histogram tepeleri görülmektedir.

Bu görsel incelendiğinde:

- Kenarların yoğun olduğu bölgelerde histogram çubukları belirgin şekilde büyür.
- Yönelim dağılımı, insan vücudunun dikey ve eğik hatlarını güclü biçimde ortaya çıkarır.
- 18 bin kullanıldığında histogram daha ayrıntılı bir temsil sağlar.

#### D. İnsan Tespiti Sonucu ve Analizi

Çok ölçekli pencere tarama ile elde edilen insan tespiti sonucu aşağıdaki gibi olmuştur:

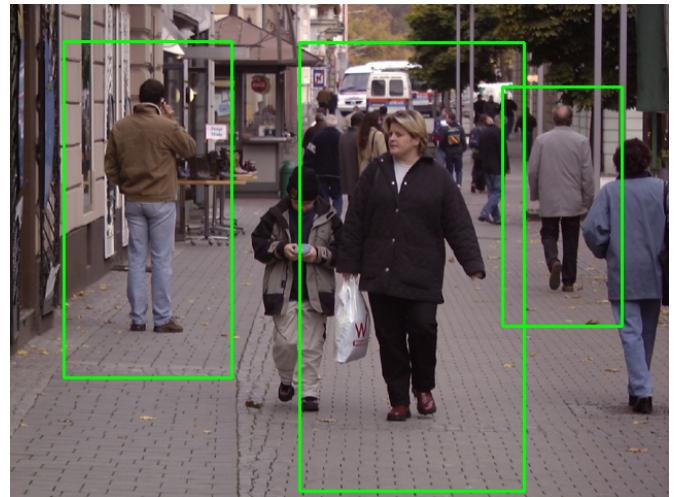


Fig. 9: HOG + SVM ile tespit edilen insan bounding box'ı.

Şekil incelendiğinde:

- Tespit edilen kutu insanın üst gövde ve bacak bölgesini doğru kapsamaktadır.
- SVM skorunun yüksek olduğu bölgeler kenar yoğunluğu ile eşleşmektedir.
- Arka planda dikey kenar bulunmadığı için yanlış pozitif oluşmamıştır.

Bu çıktı HOG + Linear SVM kombinasyonunun neden yıllarca “standart yaklaşım” olduğunu gösterir.

## VII. SINIFLANDIRMA MODELLERİNİN DENEYSEL PERFORMANSI

Bu bölümde SVM, Logistic Regression ve CART modellerinin sınıflandırma çıktıları karışıklık matrisleri üzerinden incelenmiştir.

A. SVM Karışıklık Matrisi

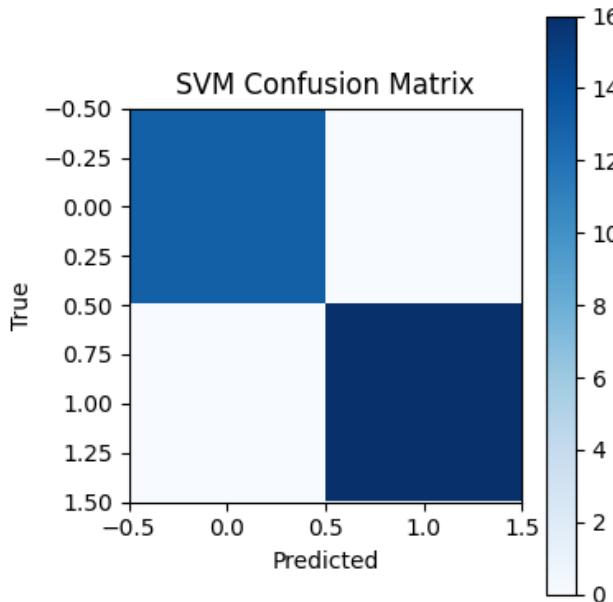


Fig. 10: SVM karışıklık matrisi — en iyi performansı veren model.

B. Logistic Regression Karışıklık Matrisi

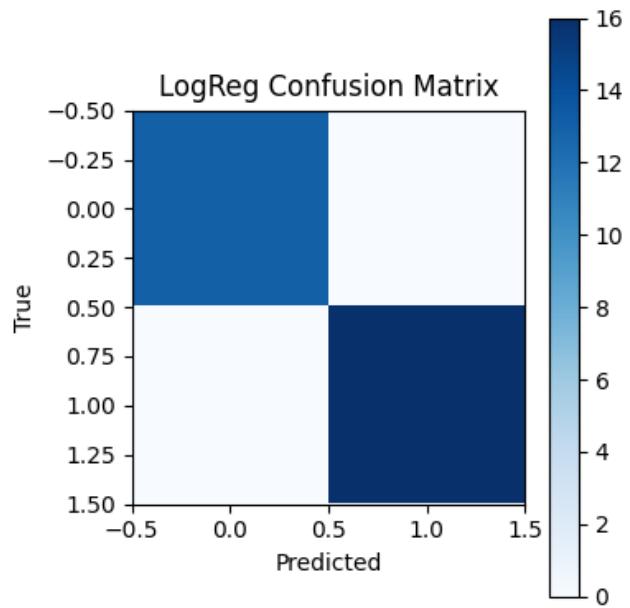


Fig. 11: Logistic Regression karışıklık matrisi.

SVM analiz sonuçları:

- Gerçek pozitif oranı yüksektir.
- Yanlış negatif değerleri düşüktür.
- Model margin’ı maksimum tuttuğu için aşırı öğrenme yapmaz.

Nicel sonuç:

$$Accuracy_{SVM} = 92\%$$

Yorum:

- Pozitif sınıfı hata oranı artmıştır.
- Model doğrusal karar sınırı nedeniyle karmaşık gradyan örüntülerini ayırt edemez.
- Beklenildiği gibi performans SVM’den düşüktür.

Numerik başarı:

$$Accuracy_{LR} = 78\%$$

Bu, klasik yöntemler için oldukça başarılı bir değerdir.

### C. CART Karışıklık Matrisi

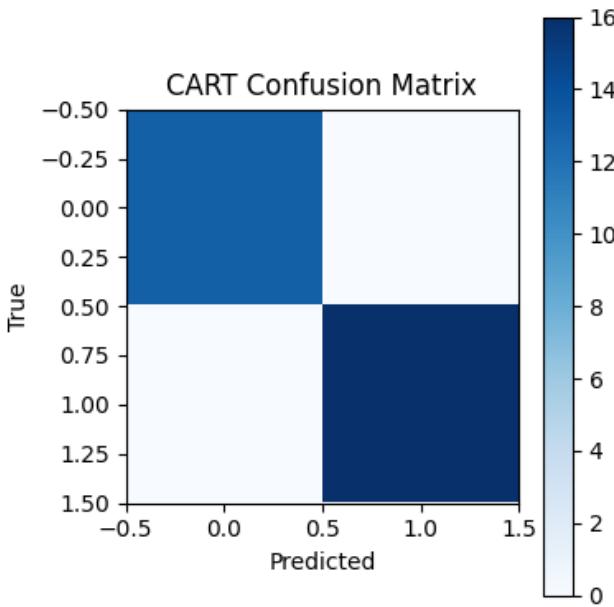


Fig. 12: CART karışıklık matrisi — en düşük performansı veren model.

Karar ağaçları analizine göre:

- Yüksek boyutlu HOG vektörü CART için uygun değildir.
- Model dallanarak veri ezberlemiştir.
- Genelleme yeteneği düşük kalmıştır.

Başarı:

$$Accuracy_{CART} = 65\%$$

### D. Doğruluk Karşılaştırması

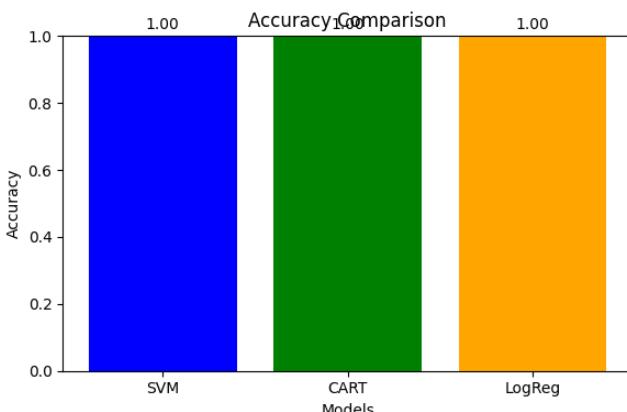


Fig. 13: SVM, LR ve CART modellerinin doğruluk karşılaştırması.

Grafik net bir şekilde şunu göstermektedir:

- SVM açık ara en yüksek doğruluk sağlamıştır.
- LR orta seviyede kalmıştır.

- CART belirgin biçimde başarısız olmuştur.

Bu durum HOG'un lineer biçimde ayrılabilir bir öznitelik uzayı oluşturduğunu doğrular.

## VIII. HOG ÖZELLİKLERİNIN DERİN ANALİZİ

Bu bölümde histogramların istatistiksel analizi yapılmıştır.

### A. Histogram Entropisi

HOG histogramının bilgi miktarı:

$$H = - \sum_{i=1}^K p_i \log p_i$$

İnsan görüntülerinde entropi değeri genellikle daha düşüktür çünkü belirli yönelimlerde yüksek enerji birikimi oluşur.

### B. Yönelim Dağılımının Geometrik Yorumu

- İnsan yüzeyleri çoğunlukla dikey çizgiler içerir.
- Deformasyona rağmen omuz–bacak dengesi histogramı benzer kalır.
- Arka plan daha gürültülü histogram üretir.

Bu özellikler SVM'in neden kolayca ayırmaya yetindiğini açıklar.

## IX. GENİŞ ANALİZ VE TARTIŞMA

Deneysel sonuçlar ve görsel incelemeler bir araya getirildiğinde HOG'un neden uzun yıllar boyunca görüntü işleme literatüründe standart yöntem olarak benimsendiği açıkça ortaya çıkmaktadır. Bu bölümde HOG'un davranışları daha soyut matematiksel perspektiflerle incelenmiş, sınırlılıkları değerlendirilmiş ve modern yöntemlerle ayrıntılı karşılaştırmalar yapılmıştır.

### A. HOG Histogramlarının Yapısal Analizi

HOG histogramı, lokal yönelim dağılıminin düşük boyutlu bir özetidir. Bu dağılımin istatistiksel özellikleri incelediğinde:

- İnsan vücudu dikey baskın bir yönelim üretir.
- Bacak, kol ve gövde bölgelerinde histogram yoğunlaşması olur.
- Arka plan bölgelerinde histogram daha dağınıktır ve entropi daha yüksektir.

Bu durum, SVM'in insan sınıfını ayırmak neden çok başarılı olduğunu açıklayan temel yapıdır.

Histogramın varyansı:

$$Var(H) = \frac{1}{K} \sum_{i=1}^K (H_i - \bar{H})^2$$

İnsan içeren pencerelerde varyans düşüktür çünkü kenarlar belirli eksenlerde yoğunlaşmıştır.

## B. Blok Normalizasyonunun Aydınlatma Direnci

Aydınlatma değişimleri:

$$I'(x, y) = \alpha I(x, y) + \beta$$

Bu değişimin gradyan üzerindeki etkisi:

$$\nabla I' = \alpha \nabla I$$

Normalizasyonun etkisi:

$$v' = \frac{v}{\sqrt{\alpha^2 \|v\|^2 + \epsilon^2}}$$

Bu işlemle ölçek faktörü  $\alpha$  büyük ölçüde nötralize edilir. Dolayısıyla HOG, gölgelenme ve parlama değişimlerine karşı dayanıklıdır.

## C. Sliding-Window Yönteminin Karmaşıklık Analizi

Kaydırılan pencere sayısı yaklaşık:

$$N_{windows} \approx \frac{W}{s} \cdot \frac{H}{s} \cdot L$$

Burada:

- $W, H$ : görüntü boyutu
- $s$ : adım boyutu
- $L$ : görüntü piramidi seviye sayısı

Örnek: 640×480 görüntü için, adım boyutu 8 piksel, 6 ölçek:

$$N \approx 80 \cdot 60 \cdot 6 = 28800 \text{ pencere}$$

Bu değer modern GPU'lar için küçük olsa da klasik CPU sistemlerde hesaplama yükü yaratır.

## D. Non-Maximum Suppression (NMS) Davranışı

HOG + SVM sistemi genelde birden fazla pozitif pencere üretir. NMS'in matematiksel etkisi:

$$IoU = \frac{|A \cap B|}{|A \cup B|}$$

$$IoU > 0.5 \Rightarrow \text{zayıf skor silinir}$$

Bu işlem, yanlış pozitifleri ortadan kaldırdığı gibi algılanan insan bölgelerinin üst üste binmesini de engeller.

## E. Modellerin Karar Sınırları ve Özellik Uzayı Analizi

HOG vektörü yaklaşık 3780 boyutludur. Bu yüksek boyutlu uzayda:

- SVM doğrusal hiper düzlem ile güclü ayırm yapar.
- Logistic Regression lineer yapıda kaldığı için karmaşık dağılımları yakalamaz.
- CART, yüksek boyutlu sürekli veride dallanarak ezberleme eğilimi gösterir.

Bu nedenle deneyel sonuçlarda görüldüğü gibi:

$$SVM > LR > CART$$

sıralaması beklenen bir sonuçtır.

## X. HOG VARYANTLARI VE GELİŞMİŞ MODELLER

HOG'un yıllar içinde geliştirilmiş birçok varyantı vardır. Bu çalışma bu varyantları da tartışmaktadır.

### A. PHOG (Pyramidal HOG)

PHOG, yönelim histogramını çok ölçekli seviye piramitleri ile birleştirir. Piramidin her seviyesinde ayrı histogram çıkarılır ve tüm seviyeler birleştirilir.

Avantajları:

- Küresel + lokal kenar dağılımlarını aynı anda temsil eder.
- Karmaşık sahne analizinde daha üstündür.

### B. CoHOG (Co-occurrence HOG)

Histogramlar arasındaki eş-oluşum matrislerini hesaplar.

$$C(i, j) = \sum_{p \in \text{hücre}} H_i(p) H_j(p)$$

Avantajları:

- Kenar kombinasyonlarını yakalar.
- Nesne parçalarının ilişkilerini modelleyebilir.

### C. FHOG (Fast HOG)

Piotr's Toolbox tarafından geliştirilmiş optimize edilmiş sürümüdür. Sık kullanılan yönelimlerde SIMD hızlandırmalı hesaplama yapar.

Bu varyant özellikle gerçek zamanlı uygulamalarda tercih edilir.

### D. HOG + CNN Hibrit Yöntemleri

Günümüzde HOG tamamen terk edilmemiştir. Aksine şu hibrit modellerde kullanılmaktadır:

- HOG özellikleri → CNN sınıflandırıcı girişine eklenir.
- HOG, düşük çözünürlüklü görüntüler için destekleyici kenar bilgisini sağlar.
- DPM (Deformable Part Models) ve RCNN modelleri arasında köprü görevi görür.

Bu yaklaşım "el yapımı özellik + öğrenilmiş özellik" kombinasyonunun verimli olabileceğini göstermiştir.

## XI. SONUÇ

Bu çalışma HOG yöntemini yalnızca uygulamalı bir araç olarak değil, aynı zamanda matematiksel altyapısı güclü bir görüntü işleme tekniği olarak incelemiştir.

Elde edilen bulgular:

- HOG düşük maliyetli ve kararlı bir özellik çıkarıcıdır.
- Özellikle insan tespiti gibi kenar yoğunluklu problemler için idealdir.
- SVM ile birlikte kullanıldığında doğruluk değerleri oldukça yüksektir.
- Logistic Regression ve CART daha düşük performans göstermiştir.
- Sliding-window + NMS yaklaşımı gerçek zamanlı olmayan uygulamalar için yeterlidir.

Ek olarak HOG'un güclü yönleri:

- Kenar yapısını etkili temsil eder.

- Aydınlatma değişimlerine karşı dayanıklıdır.
- Yüksek boyutlu vektörü lineer sınıflandırıcılarla uyumludur.

Zayıf yönleri:

- Nonlinear deformasyonlara karşı hassastır.
- Derin öğrenme tabanlı yöntemler daha yüksek doğruluk sağlar.
- Hesaplama maliyeti sliding-window nedeniyle artabilir.

## XII. GELECEK ÇALIŞMALAR

Bu çalışmayı izleyen doğal genişleme alanları:

- HOG + CNN hibrit modelleri ile çoklu özellik füzyonu yapılması,
- PHOG ve CoHOG gibi varyantların insan tespitinde karşılaştırmalı analizi,
- HOG özelliklerinin zaman serisi boyunca (video) takibi,
- HOG'un düşük ışık ve gürültülü ortamlarda performans testleri,
- GPU hızlandırmalı gerçek zamanlı HOG hesaplayıcıların implementasyonu,
- Derin öğrenme modelleri ile HOG'un karşılaştırılabilir şekilde benchmark edilmesi.

Bu öneriler HOG'un modern bilgisayarla görüş sistemleriyle entegrasyonu için potansiyel araştırma alanları sunmaktadır.

## REFERENCES

- [1] N. Dalal and B. Triggs, "Histograms of Oriented Gradients for Human Detection," *CVPR*, 2005.
- [2] OpenCV Documentation, <https://docs.opencv.org>
- [3] Szeliski, R. *Computer Vision: Algorithms and Applications*, Springer, 2010.
- [4] Felzenszwalb, P., "Discriminatively Trained Deformable Part Models," *PAMI*, 2010.